Python para Data Science

Gabriel Cabas

¿Qué es Python?

Python es un lenguaje de programación:

- Interpretado: no requiere compilación explícita
- Multi Paradigma: procedural, orientado a objetos, funcional.
- De alto nivel: abstrae detalles de memoria.
- Con sintaxis simple y legible

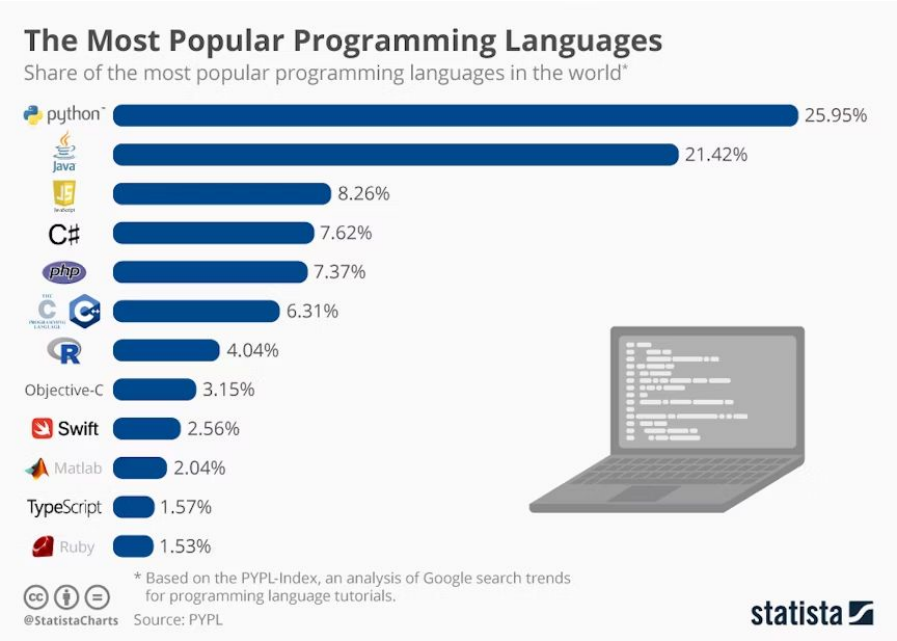

¿Por qué utilizarlo?

En Data Science trabajamos con:

- Matrices grandes
- Estadística
- Modelos de ML
- Visualización
- Pipelines reproducibles
- Python permite hacer todo eso dentro del mismo ecosistema.

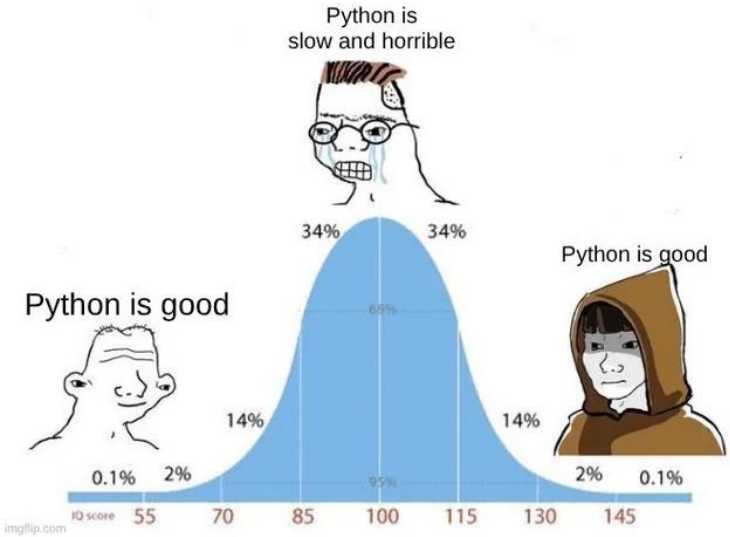

Python es lento: ¿Verdad o mito?

Un lenguaje interpretado nunca será más rápido que uno compilado. Al requerir un intérprete, debe realizar pasos extra, lo que lo vuelve más lento.

Sin embargo, podemos extender Python utilizando librerías escritas en C/C++. Esto nos da lo mejor de ambos mundos.

Velocidad para procesar datos, y una sintaxis más cómoda para el programador. Mayor productividad y resultados.

```
(ml_course) C:\Users\Gabriel\Desktop\python>run_benchmarks.bat
==========================================
  COMPARATIVA: C, C++, Python, Python+NumPy
  Operación: sum(sqrt(x2+1) * sin(x)), 50M elementos
==========================================

[1/4] Ejecutando C...
C (loop)
  Iteraciones: 50000000
  Resultado (suma): 27881398.932740
  Tiempo: 220.00 ms

[2/4] Ejecutando C++...
C++ (loop)
  Iteraciones: 50000000
  Resultado (suma): 2.78814e+07
  Tiempo: 198 ms

[3/4] Ejecutando Python (loop puro)...
Python (loop puro)
  Iteraciones: 50,000,000
  Resultado (suma): 27881398.932740305
  Tiempo: 15911.33 ms

[4/4] Ejecutando Python + NumPy...
Python + NumPy (vectorizado)
  Elementos: 50,000,000
  Resultado (suma): 27881399.565126758
  Tiempo: 878.84 ms

==========================================
  Fin de la comparativa
==========================================
Presione una tecla para continuar . . .
```

Librerías a utilizar en el curso.

- Numpy: Álgebra lineal.
- Pandas: Dataframes y manipulación de datos.
- Matplotlib + Seaborn: Visualización
- Scikit-learn: Machine Learning.
- Pytorch: Deep Learning.

Tipos de datos

Simples:

- int: Números enteros.
- float: Números decimales.
- str: Cadenas de caracteres.
- bool: Boolean (True o False).

Compuestos:

- Listas.
- Sets.
- Diccionarios.
- Tuplas.

[Notebook]

```python
a = 10
b = 0.5
c = "Hola"
d = True
print("a es un número entero: ", a)
print("b es un número decimal: ", b)
print("c es una cadena de caracteres: ", c)
print("d es un booleano: ", d)
```

[9] ✓ 0.0s Python

```
a es un número entero:  10
b es un número decimal:  0.5
c es una cadena de caracteres:  Hola
d es un booleano:  True
```

```python
t = (1, 2, 3, 3, 4, 5, 5) #Tuplas
l  = [1, 2, 3, 3, 4, 5, 5] #Listas
s = {1, 2, 3, 3, 4, 5, 5} #Sets
d = {"Gabriel": 26, "Susan": 34, "Evelin": 34} #Diccionarios
print("Tupla: ", t)
print("Lista: ", l)
print("Set: ", s)
print("Diccionario: ", d)
```

[142] ✓ 0.0s Python

```
Tupla:  (1, 2, 3, 3, 4, 5, 5)
Lista:  [1, 2, 3, 3, 4, 5, 5]
Set:  {1, 2, 3, 4, 5}
Diccionario:  {'Gabriel': 26, 'Susan': 34, 'Evelin': 34}
```

Condicionales y loops

- Los condicionales permiten tomar decisiones ejecutando bloques de código específicos basados en condiciones verdaderas o falsas.
  - if: Si se cumple la condición.
  - else: Si no se cumple.
  - elif: else + if.
- Los loops permiten ejecutar un bloque de código repetidamente:
  - while: Mientras se cumpla una condición dada.
  - for: Itera un número conocido de veces.

[Notebook]

Condicionales

```python
if d["Gabriel"] < 18:
    print("Gabriel es menor de edad")
elif (d["Gabriel"] >= 18) and (d["Gabriel"] <= 100):
    print("Gabriel es un adulto")
else:
    print("Gabriel es viejito")
```

[26] ✓ 0.0s Python

```
Gabriel es un adulto
```

Add Code Add Markdown

Loops

```python
for persona in d:
    print(persona, "tiene", d[persona], "años")
```

[29] ✓ 0.0s Python

```
Gabriel tiene 26 años
Susan tiene 34 años
Evelin tiene 34 años
```

Numpy

Es una librería fundamental en Python para computación científica y análisis de datos. Sus funciones clave permiten crear, manipular y operar eficientemente con arrays n-dimensionales (ndarrays).

Incluye funciones de álgebra lineal, descomposiciones matriciales y estadística descriptiva.

[Notebook]

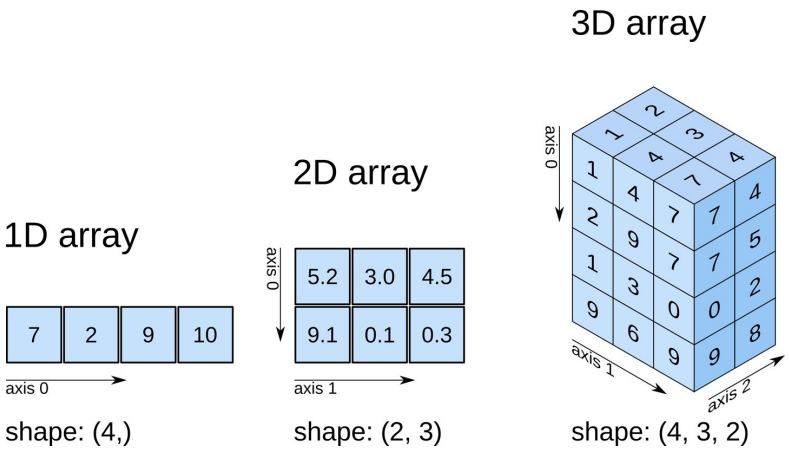

Pandas

Manipulación y análisis de datos estructurados, especialmente en formato tabular mediante DataFrames.

Está montado sobre numpy, por lo que las operaciones realizadas son altamente eficientes.

[Notebook]

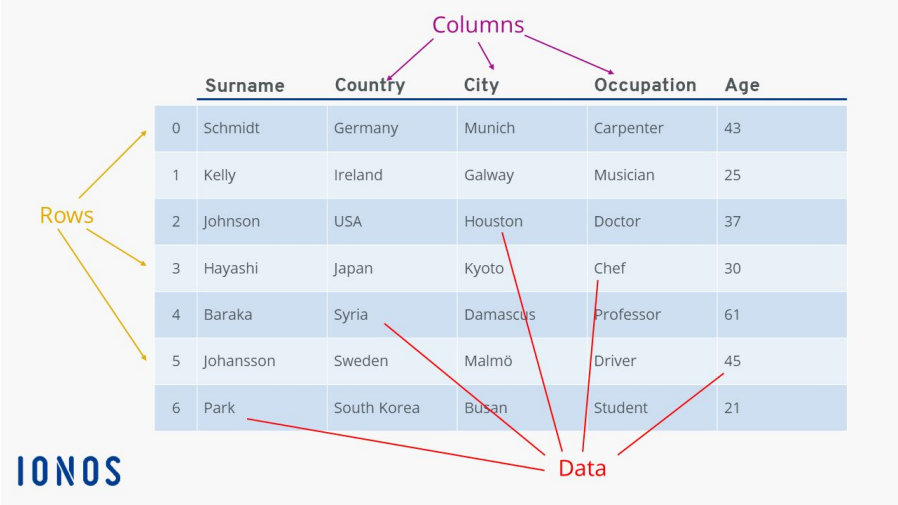

	Surname	Country	City	Occupation	Age
0	Schmidt	Germany	Munich	Carpenter	43
1	Kelly	Ireland	Galway	Musician	25
2	Johnson	USA	Houston	Doctor	37
3	Hayashi	Japan	Kyoto	Chef	30
4	Baraka	Syria	Damascus	Professor	61
5	Johansson	Sweden	Malmö	Driver	45
6	Park	South Korea	Busan	Student	21

Matplotlib y seaborn

Matplotlib: Biblioteca base de visualización en Python que ofrece control detallado para crear gráficos estáticos, personalizables y de alta calidad.

Seaborn: Librería de visualización construida sobre Matplotlib que simplifica la creación de gráficos estadísticos atractivos e informativos.

[Notebook]

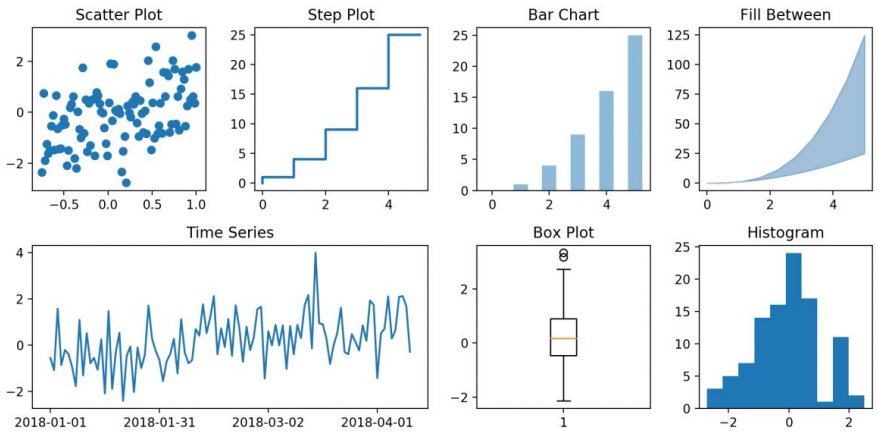

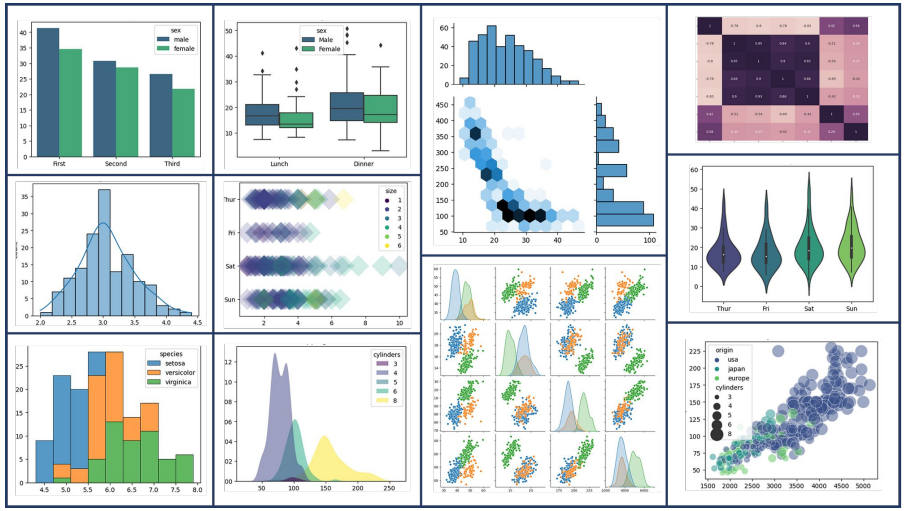

Tarea motivacional

Por 2 décimas en la prueba 1.

Realizar un Exploratory Data Analysis en el dataset [Titanic](#).

Este debe ser subido a un repositorio público propio.

Enviar el link al repositorio por mensaje interno de Ucampus.

Plazo 1 semana.

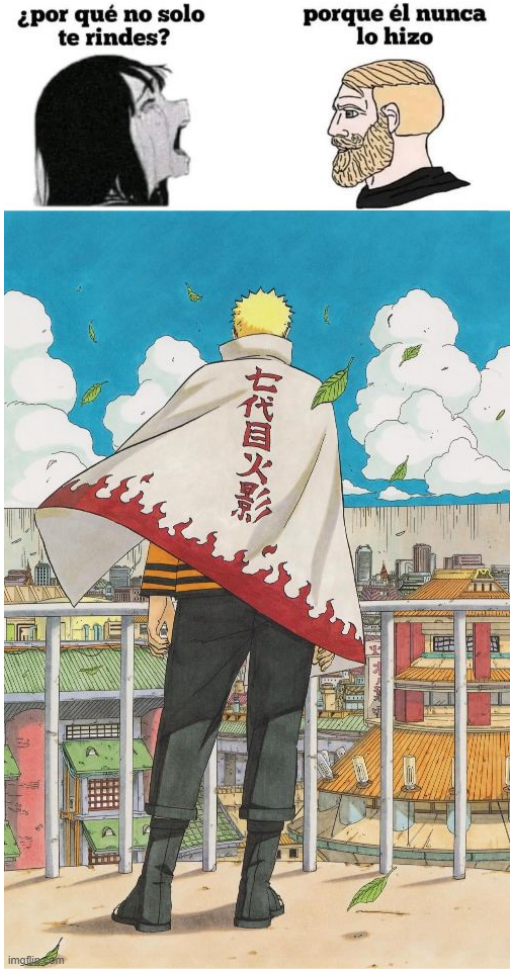

Python para Data Science

Gabriel Cabas