Modelos lineales para regresión

Gabriel Cabas

Modelos lineales

El modelo más simple que podemos crear es una combinación lineal de los valores de entrada.

$$y(\mathbf{x}, \mathbf{w}) = w_0 + w_1 x_1 + \ldots + w_D x_D$$

Es símplemente conocido como *regresión lineal*. Este modelo es lineal respecto a los parámetros w_i y a los valores de entrada x_i

Sin embargo, podemos extender este tipo de modelos para considerar las combinaciones lineales de funciones no lineales.

$$y(\mathbf{x}, \mathbf{w}) = w_0 + \sum_{j=1}^{M-1} w_j \phi_j(\mathbf{x}) \qquad y(\mathbf{x}, \mathbf{w}) = \sum_{j=0}^{M-1} w_j \phi_j(\mathbf{x}) = \mathbf{w}^{\mathrm{T}} \boldsymbol{\phi}(\mathbf{x})$$

Donde $\boldsymbol{\phi}_j(x)$ reciben el nombre de *funciones base.*

Existen muchas funciones base que se pueden utilizar

- Identidad
- Polinomiales
- Gaussianas
- Sigmoidales

La idea principal de esta clase es independiente de la elección de las funciones base.

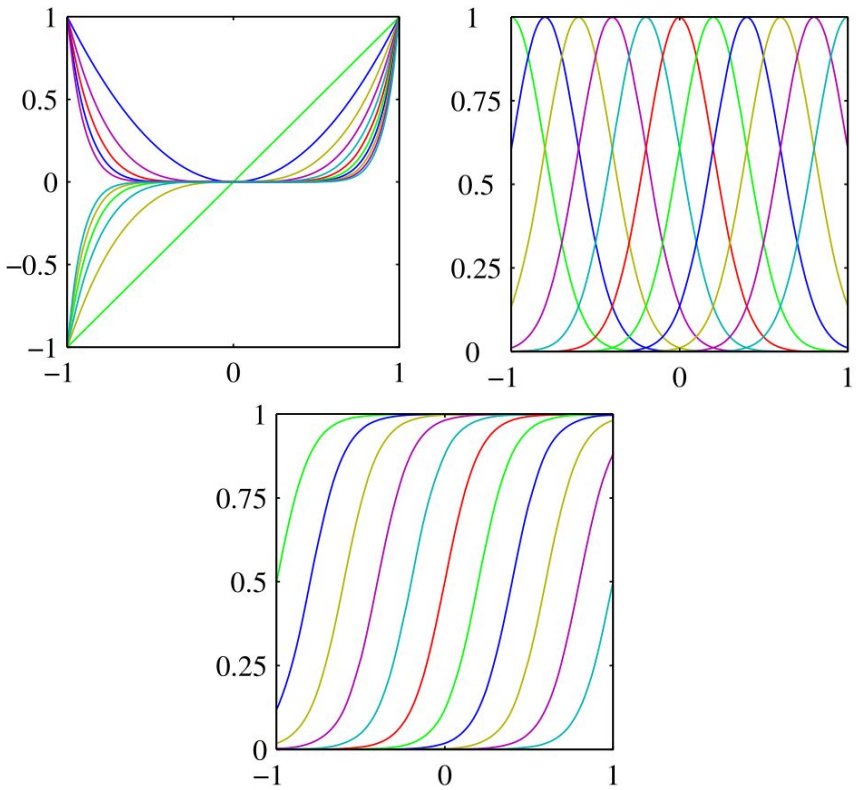

Maximum likelihood estimation

En el ejemplo de la clase anterior nos preocupamos por optimizar el Least-Squares error.

$$E_D(\mathbf{w}) = \frac{1}{2}\sum_{n=1}^{N}\{t_n - \mathbf{w}^{\mathrm{T}}\boldsymbol{\phi}(\mathbf{x}_n)\}^2$$

Pero ¿Cómo obtenemos esta función? Ahí es donde necesitamos utilizar *maximum likelihood estimation.*

Matriz inversa

Def: Una matriz A es invertible si existe una matriz B tal que AB = I y BA = I. Hay a lo sumo una B con estas características, denominada inversa de A y se denota como B=A^{-1}.

$$AA^{-1} = A^{-1}A = I$$

Las inversas nos permiten resolver la ecuación $Ax = b$

Donde A y b son matrices conocidas y b es una incógnita.

$$Ax = b \rightarrow A^{-1}Ax = A^{-1}b \rightarrow x = A^{-1}b$$

Para lograrlo, A debe ser una matriz cuadrada e invertible (det(A) != 0). Esto no se cumple en la gran mayoría de casos.

Pseudoinversa de Moore-Penrose

Si tenemos A una matriz de dimensión NxM, con N>M.

La Pseudo-inversa se define como la matriz.

$$A^{+} = (A^{T}A)^{-1}A^{T}$$

En el caso de N<M

$$A^{+} = A^{T}(A^{T}A)^{-1}$$

Podemos verificar si se comporta como si fuera una inversa al multiplicar A por la derecha e izquierda respectivamente.

A^{+} es equivalente a minimizar los least squares para el caso sobredeterminado, y es la matriz de norma mínima para el caso subdeterminado.

Ejercicio

Suponiendo que nuestros datos son los siguientes:

X = (1, 2, 3)

Nuestra variable de respuesta es:

y = (3, 5, 7)

Genere una matriz de diseño de 1 grado y obtenga su pseudoinversa.

Una vez realizado, obtenga los parámetros de su modelo lineal.

Sequential learning

Usar la pseudoinversa puede ser costoso computacionalmente para datasets muy grandes. En estos casos, utilizar algoritmos secuenciales es una mejor opción.

$$\mathbf{w}^{(\tau+1)} = \mathbf{w}^{(\tau)} - \eta \nabla E_n$$

Podemos aplicar la técnica de stochastic gradient descent (SGD). Este algoritmo actualiza el vector de parámetros w en la iteración τ + 1.

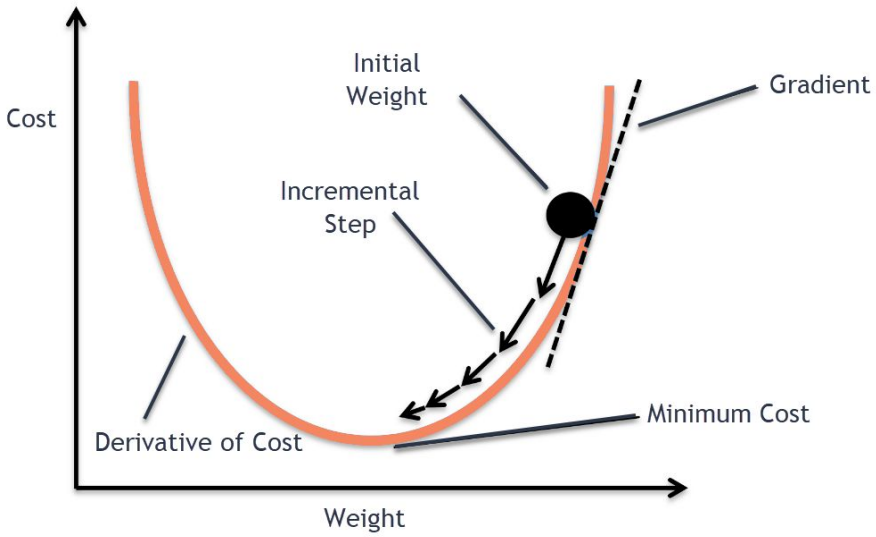

Bias-Variance Decomposition

El error total se puede descomponer en dos tipos de errores. Estos son el *bias* y la *variance.*

- Bias: La inhabilidad de una función para capturar la verdadera señal.
- Variance: La cantidad por la que las predicciones deberían cambiar si ajustamos el modelo a un dataset distinto.
- Adicionalmente, los datos del mundo real contarán con ruido, con el que tendremos que convivir.

La idea es minimizar tanto el *bias* como la *variance* por medio de regularización.

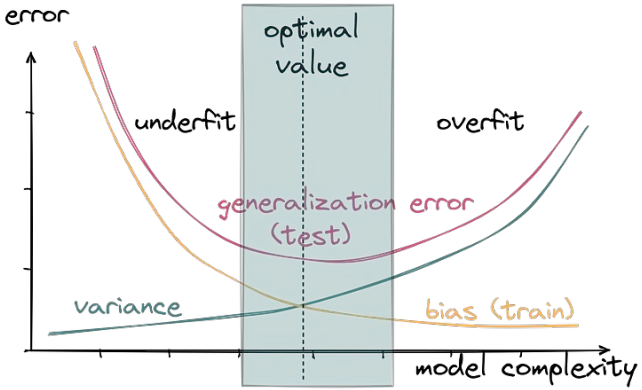

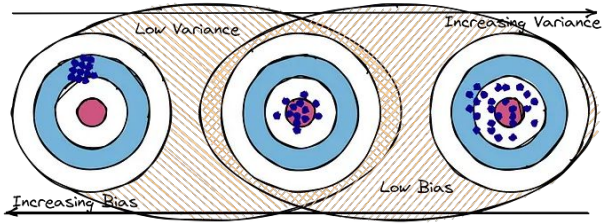

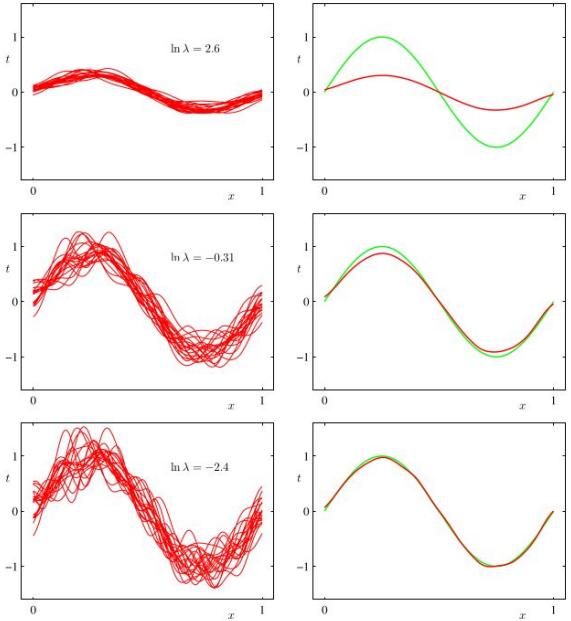

Regularized least squares

En la clase anterior utilizamos un término de regularización para controlar el overfitting. El error total a minimizar tendrá esta forma:

$$E_D(\mathbf{w}) + \lambda E_W(\mathbf{w})$$

Uno de los regularizadores más simples es la suma de cuadrados del vector de pesos.

$$E_W(\mathbf{w}) = \frac{1}{2}\mathbf{w}^{\mathrm{T}}\mathbf{w}.$$

Entonces el error total se convierte en:

$$\frac{1}{2}\sum_{n=1}^{N}\{t_n - \mathbf{w}^{\mathrm{T}}\boldsymbol{\phi}(\mathbf{x}_n)\}^2 + \frac{\lambda}{2}\mathbf{w}^{\mathrm{T}}\mathbf{w}.$$

Este regularizador recibe el nombre de *weight decay*, porque lleva a los pesos a “decaer” hacia el cero. También se conoce como *Ridge* o *L2*.

Podemos utilizar maximum likelihood para encontrar el W_{ML}.

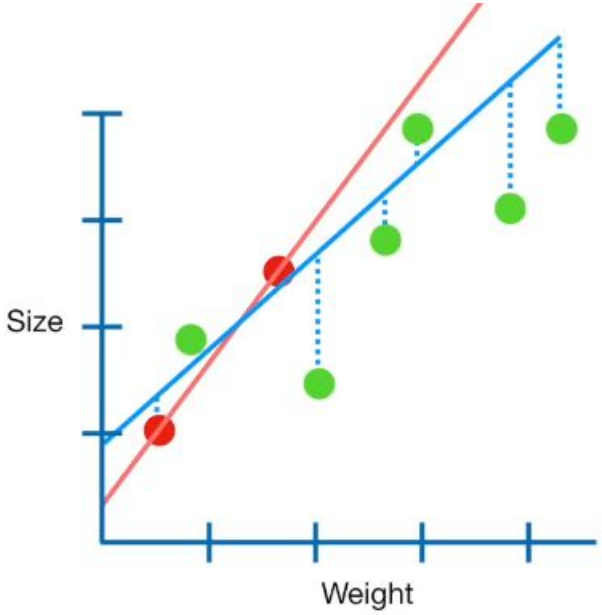

Regularizador general

Podemos usar un regularizador general de la forma

$$\frac{1}{2}\sum_{n=1}^{N}\{t_n - \mathbf{w}^{\mathrm{T}}\boldsymbol{\phi}(\mathbf{x}_n)\}^2 + \frac{\lambda}{2}\sum_{j=1}^{M}|w_j|^q$$

Donde *q=2* corresponde al caso anterior (*Ridge*). El caso de *q=1* recibe el nombre de *Lasso* o *L1.*

Fijarse en la interpretación geométrica de los regularizadores.

¿Qué hace a lasso especial? ¿Para qué lo podemos ocupar?

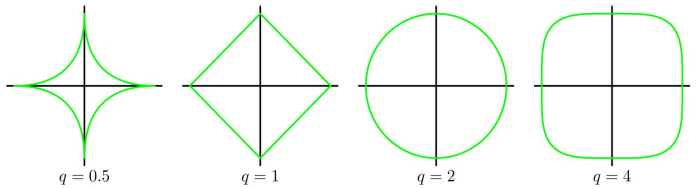

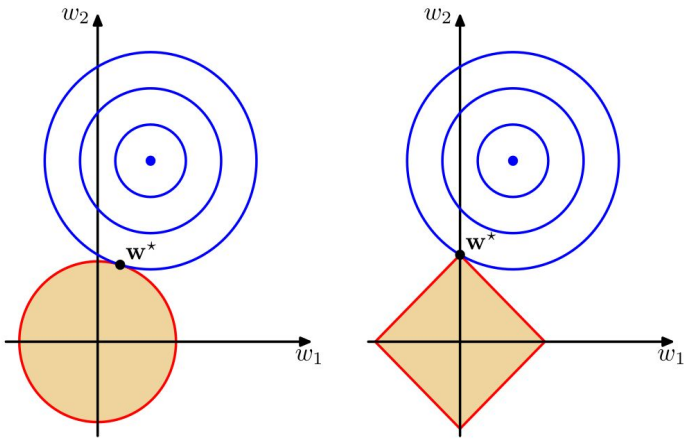

ElasticNet

Podemos combinar Lasso y Ridge en una sola función de pérdida a minimizar.

$$\frac{1}{2n_{\text{samples}}} \cdot \|y - Xw\|_2^2 + \alpha \cdot \text{l1_ratio} \cdot \|w\|_1 + 0.5 \cdot \alpha \cdot (1 - \text{l1_ratio}) \cdot \|w\|_2^2$$

Podemos combinar Lasso y Ridge en una sola función de pérdida a minimizar.

Lasso se encargará de seleccionar variables.

Ridge reducirá las magnitudes de las seleccionadas para garantizar mayor estabilidad.

Métricas de desempeño

Ya hemos hablado de las loss functions como funciones a optimizar al momento de entrenar un modelo.

Sin embargo, nos gustaría evaluar el desempeño de este en nuevos datos.

En este caso, las mismas loss functions no son suficientes, ¿por qué?

¡Porque tienen términos regularizadores que cambian su valor!

Una mejor práctica sería complementar con otras funciones como métricas de desempeño.

$$MAE = \frac{1}{n}\sum_{i=1}^{n} | y_i - \hat{y}_i | \in [0, +\infty)$$

$$MSE = \frac{1}{n}\sum_{i=1}^{n} (y_i - \hat{y}_i)^2 \in [0, +\infty)$$

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n} (y_i - \hat{y}_i)^2} \in [0, +\infty)$$

$$MAPE = \frac{100\%}{n}\sum_{i=1}^{n} \left| \frac{y_i - \hat{y}_i}{y_i} \right| \in [0, +\infty)$$

$$R^2 = 1 - \frac{\sum_{i=1}^{n} (y_i - \hat{y}_i)^2}{\sum_{i=1}^{n} (y_i - \bar{y}_i)^2} \in [0, 1]$$

Mean Squared Error (MSE) y Root Mean Squared Error (RMSE)

MSE

- Penaliza más los errores grandes debido a la elevación al cuadrado.
- Muy útil cuando los errores grandes deben ser castigados más.
- No es directamente interpretable en las mismas unidades que la variable objetivo.

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

RMSE

- Se interpreta en las mismas unidades que la variable objetivo.
- Es más intuitivo que el MSE.

$$RMSE = \sqrt{MSE}$$

Mean absolute error (MAE) y Huber Loss

MAE

- Mide el error promedio sin elevarlo al cuadrado.
- No penaliza tanto los errores grandes como el MSE.
- Es más robusto a outliers que el MSE.

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

Huber loss

- Es cuadrático para errores pequeños y lineal para errores grandes.
- Muy útil si hay outliers.

$$L_\delta(y, f(x)) = \begin{cases} \frac{1}{2}(y - f(x))^2 & \text{for } |y - f(x)| \le \delta, \\ \delta \cdot \left(|y - f(x)| - \frac{1}{2}\delta\right), & \text{otherwise.} \end{cases}$$

R^2, varianza explicada o coeficiente de determinación.

- Indica qué proporción de la variabilidad de los datos es explicada por el modelo.
- Rango: $(-\infty, 1]$, donde 1 indica un modelo perfecto y valores negativos indican un modelo peor que la media.
- No siempre es una buena métrica si el modelo no es lineal.
- Como el nombre lo indica, es el cuadrado de la correlación lineal

$$R^2 = 1 - \frac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2}$$

Cada métrica muestra algo acerca del modelo

- Si los outliers son un problema: MAE o Huber Loss.
- Si los errores grandes deben ser castigados más: MSE o RMSE.
- Si necesitas evaluar qué tan bien el modelo explica la variabilidad: R^2

$$MAE = \frac{1}{n}\sum_{i=1}^{n} | y_i - \hat{y}_i | \ \in [0, +\infty)$$

$$MSE = \frac{1}{n}\sum_{i=1}^{n} (y_i - \hat{y}_i)^2 \ \in [0, +\infty)$$

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n} (y_i - \hat{y}_i)^2} \ \in [0, +\infty)$$

$$MAPE = \frac{100\%}{n}\sum_{i=1}^{n} \left| \frac{y_i - \hat{y}_i}{y_i} \right| \in [0, +\infty)$$

$$R^2 = 1 - \frac{\sum_{i=1}^{n} (y_i - \hat{y}_i)^2}{\sum_{i=1}^{n} (y_i - \bar{y}_i)^2} \in [0, 1]$$

Práctico

Utilizando el siguiente [Dataset](#).

Predecir el valor de venta de propiedades en Santiago.

LUIS FELIPETN · UPDATED 3 YEARS AGO

28 | Code | Download

Valor Casas Usadas, Chile, RM, 18/07/2023

Avisos de venta de casas de la Region Metropolitana, Santiago

Data Card | Code (4) | Discussion (2) | Suggestions (0)

About Dataset

Datos sacados a través de un Web Scrape a https://chilepropiedades.cl/

Este dataset solo contiene CASAS en venta. No incluye departamentos o terrenos.

Al ser un Web Scrape es muy posible que hayan avisos cuya información fue ingresada incorrectamente. ej: Una casa con 100 km2 de terreno.

Contenidos

Este dataset contiene 12 columnas

-**Price_CLP**: Precio de casa en pesos chilenos (CLP)
-**Price_UF**: Precio de casa en unidades de fomento (UF)
-**Price_USD**: Precio de casa en dolares americanos (USD)
-**Comuna**: Comuna en la que se encuentra la casa.
-**Ubicacion**: Ubicación más específica de la casa
-**Dorms**: Cuantas habitaciones tiene la casa
-**Baths**: Cuantos baños tiene la casa
-**Built Area**: Cuantos metros cuadrados construidos tiene la casa
-**Total Area**: Cuantos metros cuadrados tiene toda la propiedad

Usability
10.00

License
CC0: Public Domain

Expected update frequency
Monthly

Tags
Tabular
Cities and Urban Areas
Housing | South America

Tarea motivacional

Por 2 décimas en la Prueba 1.

Mejorar el score a un r2 > 0.8 en CV.

- Este debe ser subido a un repositorio público propio.
- Plazo 1 semana.

Hint: Pueden utilizar otras fuentes de información.

Práctico

Utilizar el siguiente Dataset.

Predecir la esperanza de vida de los países a lo largo del tiempo.

Hint: Cuidado con el Data Leakage!

SAURABH BADOLE · UPDATED 2 YEARS AGO

84 | Code | Download

Life Expectancy based on Geographic Locations

Analyzing Life Expectancy Variation Across Different Geographic Locations

Data Card | Code (8) | Discussion (1) | Suggestions (0)

About Dataset

Description:

This dataset explores the factors influencing life expectancy across various countries and years, aiming to uncover patterns and disparities in health outcomes based on geographic locations. By examining key features such as adult mortality, alcohol consumption, healthcare expenditures, and socioeconomic indicators, this dataset provides insights into the complex interplay of factors shaping life expectancy worldwide.

Feature Description:

Feature	Description
Country	Name of the country
Year	Year of observation
Status	Urban or rural status
Life expectancy	Life expectancy at birth in years

Usability
10.00

License
MIT

Expected update frequency
Annually

Tags
Health | Beginner | Social Science | Intermediate

Modelos lineales para regresión

Gabriel Cabas